基于 MediaPipe 与 CNN 的多模态实时情绪检测系统设计与实现

摘要：针对单模态情绪识别在真实场景中的光照、遮挡挑战，本文设计并实现了一种基于 MediaPipe 与卷积神经网络的多模态实时情绪检测系统。系统利用 MediaPipe Face Mesh 实时提取面部 468 个三维关键点，计算眼宽高比（EAR）、嘴宽高比（MAR）、眉眼间距及嘴角曲率等几何特征；同时裁剪面部区域图像送入轻量级 CNN 提取像素级深层特征。两种模态在特征层进行融合，共同输入分类器完成七类情绪识别。在 AffectNet-7 数据集上的实验表明，双模态融合方法在分类准确率上显著优于单一模态，推理速度在普通 CPU 上可达 15 FPS，满足实时性要求。

关键词：情感计算；MediaPipe；CNN；多模态融合；面部表情识别

1 引言

本文的研究目标包括：（1）基于 MediaPipe Face Mesh 建立面部 468 个关键点的实时检测与几何特征计算流程，提取 EAR、MAR 等结构化特征向量；（2）设计轻量级 CNN 架构，从面部图像中自动学习像素级深层特征，同时控制模型参数量以适配 CPU 推理；（3）在特征层实现几何特征与像素特征的非线性融合，提升七类基本情绪的分类准确率；（4）验证系统在普通硬件环境下的实时运行能力，目标帧率不低于 15 FPS。

2 相关技术

2.1 MediaPipe Face Mesh

MediaPipe Face Mesh 是 Google 开源的面部网格检测模型，可在移动设备和桌面端实时检测面部 468 个三维关键点。468 个点均匀覆盖面部主要区域：眉眼区域约 80 点、口部区域约 80 点、鼻部区域约 40 点，其余分布于面颊和轮廓。与 OpenPose 和 Dlib 等方案相比，MediaPipe 基于先验人脸几何形状回归的两阶段管道设计在精度与计算效率之间取得了更优平衡，首先在全图范围粗检测人脸，随后在裁剪区域内进行精细关键点预测。如图 2 所示，MediaPipe Face Mesh 输出的 468 个关键点构成了密集的面部网格拓扑结构，为表情分析提供了充足的几何信息基础。

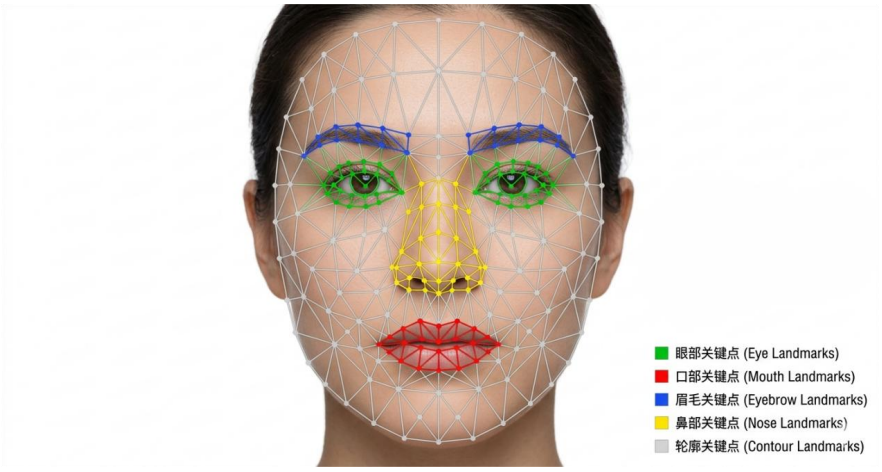

图 2　MediaPipe Face Mesh 468 关键点示意图

为消除不同拍摄距离和人脸位置带来的尺度差异，本文对关键点坐标进行归一化处理：以双眼中心点为原点、两眼间距为缩放因子，将原始坐标变换到统一的归一化坐标系中，变换关系如公式（2.1）所示：

$$p'_i = (p_i - c_eye) / d_eye \tag{2.1}$$

2.2 卷积神经网络

卷积神经网络（CNN）通过局部感受野和权值共享机制高效提取图像的层次化特征。如图 4 所示，卷积运算通过可学习滤波器在输入特征图上滑动，逐区域计算加权和以提取局部空间模式，池化层则通过下采样降低特征图的空间分辨率并增强平移不变性。

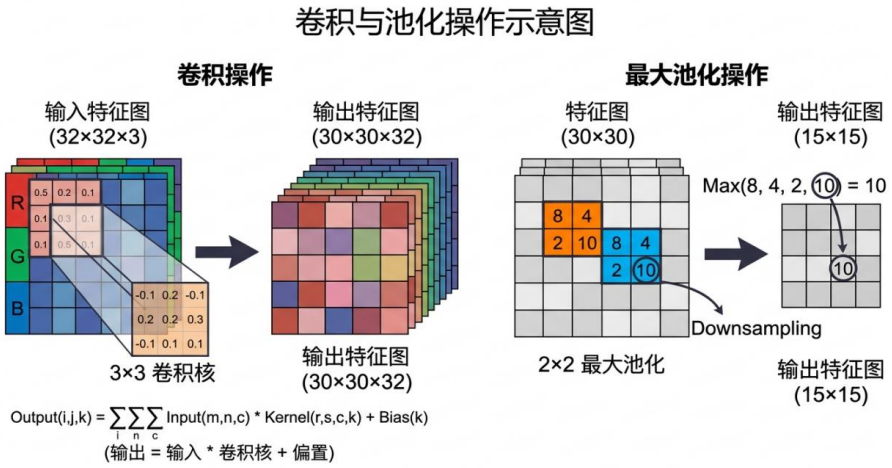

图 4 CNN 基础卷积/池化操作示意图

卷积运算的数学表达如公式（2.4）所示，其中输入特征图 x 与卷积核权重 w 进行互相关运算后加上偏置项 b 得到输出：

$$y(i,j) = \Sigma_m \Sigma_n x(i+m, j+n) \cdot w(m,n) + b \tag{2.4}$$

为引入非线性映射能力，每个卷积层后接 ReLU 激活函数，其定义如公式（2.5）所示：

$$f(x) = max(0, x) \tag{2.5}$$

对于多分类任务，网络末端通过 Softmax 函数将全连接层输出转换为各类别的概率分布，如公式（2.6）所示：

$$P(y=k|x) = exp(z_k) / \Sigma_j exp(z_j) \tag{2.6}$$

批归一化（Batch Normalization）通过对中间层输出进行标准化处理，加速训练收敛并具有一定正则化效果；Dropout 在训练过程中随机失活部分神经元，有效抑制过拟合。在本系统中，CNN 负责从面部图像中自动学习对情绪判别最具判别力的像素模式，这些模式通常对应特定的纹理变化、皱纹分布和肌肉运动痕迹，与人工设计的几何特征形成有效互补。

2.3 AffectNet 数据集

AffectNet 是目前规模最大的"in-the-wild"面部表情数据集，包含超过 100 万张从互联网采集的真实人脸图像。其中 AffectNet-7 子集提供七类基本情绪（愤怒、厌恶、恐惧、高兴、悲伤、惊讶、中性）的离散标注，训练集约 287,568 张图像，测试集约 4,000 张，图像分辨率统一为 224×224 像素。该数据集的类别分布如表 1 所示，可见高兴类占比最高（约 33%），而恐惧和厌恶类不足 3%，存在显著的类别不均衡问题。

表 1 AffectNet-7 数据集类别分布统计表

情绪类别	训练集样本数	占比 (%)
高兴	94,897	33.0
中性	75,374	26.2
悲伤	25,459	8.9

愤怒	24,882	8.7
惊讶	14,090	4.9
恐惧	6,378	2.2
厌恶	3,803	1.3
合计	**287,568**	**100.0**

与实验室环境采集的 FER2013（48×48 像素）相比，AffectNet 具有以下优势：采集场景涵盖各种光照条件、拍摄角度和背景干扰，更贴近真实应用；分辨率更高，包含更丰富的纹理细节。该数据集同样存在标注噪声（众包标注的一致性有限）等挑战，但这些恰好反映了真实场景中的典型困难，在此数据集上训练的模型具有更强的泛化能力。

3 系统总体设计

3.1 整体架构

本系统采用管道式架构，数据从采集到输出经历一系列串行处理阶段，各模块间通过明确接口通信，保持低耦合性。系统整体架构如图 5 所示，完整数据流为：摄像头采集视频帧 → MediaPipe 面部检测与关键点定位 → 几何特征计算与面部图像裁剪并行处理 → 特征层融合 → CNN 情绪分类 → 情绪标签叠加输出。

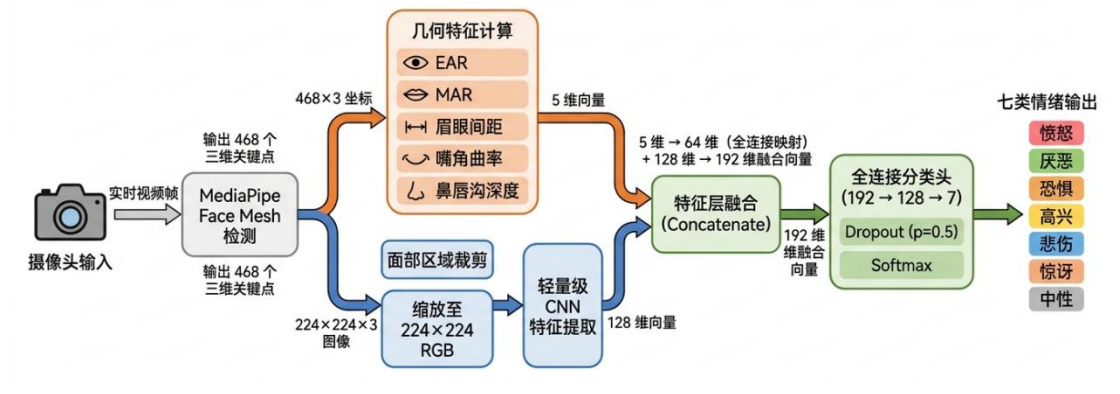

图 5 系统整体架构图

管道式设计的优势在于各模块可独立优化与测试。MediaPipe 检测模块的输出（关键点坐标和面部裁剪图像）同时服务于几何特征计算和像素特征提取两条并行分支，二者在融合模块汇合后送入分类器。

3.2 几何特征提取

MediaPipe Face Mesh 对每一帧输入图像实时检测 468 个面部三维关键点（x, y, z 坐标），输出为 468×3 的浮点数矩阵。为消除人脸与摄像头距离不同导致的尺度差异以及人脸在画面中位置不同导致的平移差异，对关键点坐标进行归一化处理：以双眼中心点为原点，以两眼间距离为缩放因子，将所有关键点变换到统一的归一化坐标系中（见公式 2.3）。

归一化后的关键点用于计算以下五项几何特征：

（1）眼宽高比（EAR）：分别计算左右眼的 EAR 值后取平均，对睁闭眼程度和眼周肌肉运动敏感。

（2）嘴宽高比（MAR）：嘴部水平宽度与垂直张开高度的比值，反映嘴部张开状态，对区分高兴、惊讶与中性表情具有判别力。

（3）眉眼间距：左右眉中心点到对应眼中心点的距离平均值，编码眉部抬起程度。

（4）嘴角曲率：基于嘴角关键点与相邻唇部关键点计算嘴角上扬或下垂的曲率值，直接关联表情的正向或负向效价。

（5）鼻唇沟深度：鼻翼两侧到嘴角的距离比值，间接反映面部肌肉紧张程度。

上述五项几何特征的提取流程如图 6 所示，从原始图像经 MediaPipe 检测、归一化变换后，逐项计算各几何指标并输出为 5 维结构化特征向量。

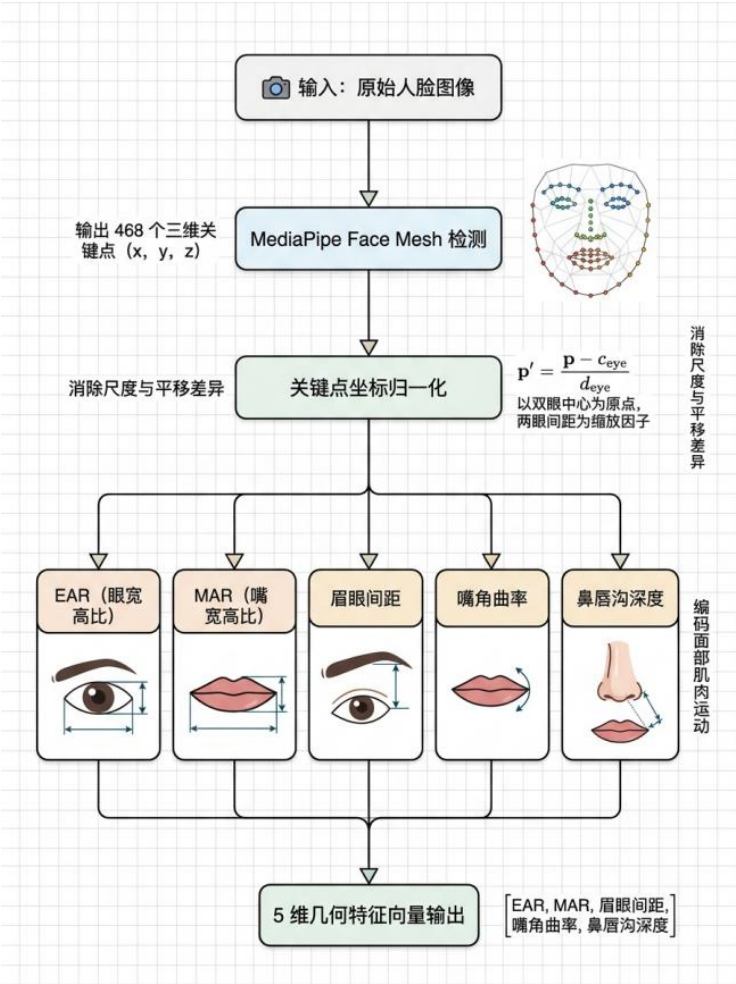

图 6 MediaPipe 特征提取流程图

上述 5 维特征向量作为多模态融合的第一路输入，与 CNN 提取的像素特征进行融合。

3.3 CNN 像素特征提取

系统基于 MediaPipe 检测到的面部关键点边界框，从原始视频帧中裁剪出面部区域，缩放至 224×224 像素，保留 RGB 三通道信息作为 CNN 输入。

CNN 架构设计遵循轻量级原则，兼顾分类性能与推理速度。网络包含 4 个卷积块，每个卷积块由 Conv2D + BatchNorm + ReLU + MaxPool2D 组成，通道数从 32 逐步增至 128（32→64→96→128），卷积核大小均为 3×3，池化核为 2×2。网络各层的输入/输出尺寸和通道数变化如图 7 所示。

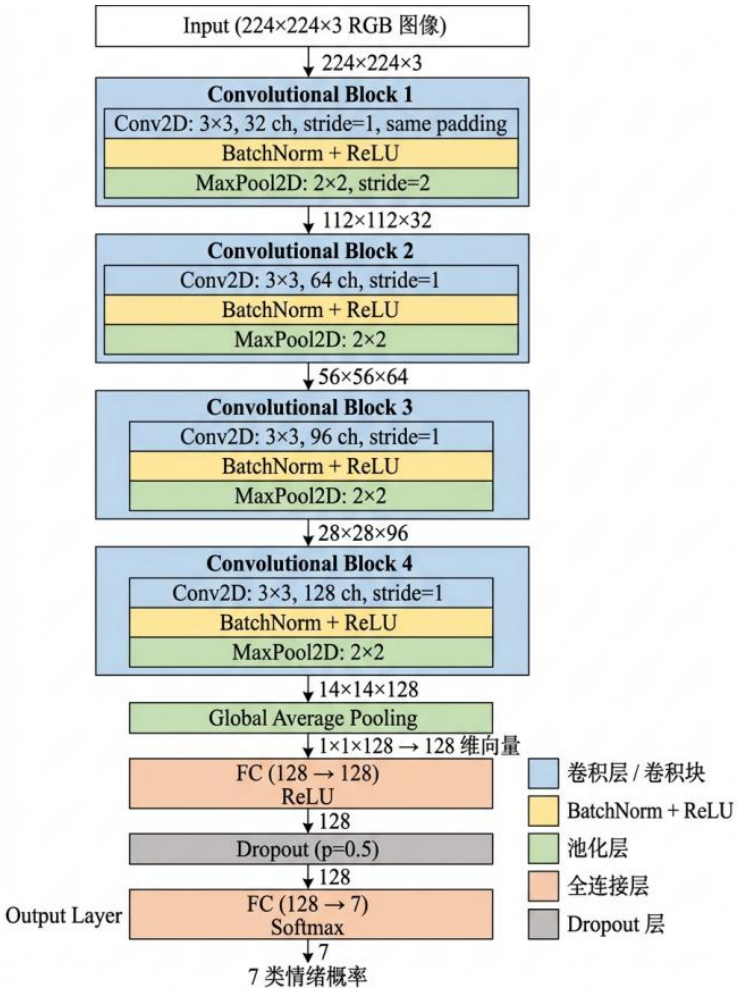

图 7 CNN 网络结构图

各层的具体参数配置如表 2 所示，包括层类型、卷积核大小、步长、输出尺寸和参数量等详细信息。

表 2 CNN 网络层详细配置表

层序号	层类型	参数配置	输出尺寸	参数量
0	Input	-	224×224×3	0
1	Conv2D	3×3, s=1, p=1	224×224×32	896
2	BatchNorm	-	224×224×32	64
3	ReLU	-	224×224×32	0

4	MaxPool2D	2×2, s=2	112×112×32	0
5	Conv2D	3×3, s=1, p=1	112×112×64	18,496
6	BatchNorm	-	112×112×64	128
7	ReLU	-	112×112×64	0
8	MaxPool2D	2×2, s=2	56×56×64	0
9	Conv2D	3×3, s=1, p=1	56×56×96	55,392
10	BatchNorm	-	56×56×96	192
11	ReLU	-	56×56×96	0
12	MaxPool2D	2×2, s=2	28×28×96	0
13	Conv2D	3×3, s=1, p=1	28×28×128	110,720
14	BatchNorm	-	28×28×128	256
15	ReLU	-	28×28×128	0
16	MaxPool2D	2×2, s=2	14×14×128	0
17	GAP	-	128	0
18	FC	128→128	128	16,512
19	Dropout	p=0.5	128	0
20	FC	128→7	7	903
-	**总计**	**-**	**-**	**203,559**

由表 2 可知，该架构的总参数量控制在百万级别以下，远低于 VGG-16、ResNet-50 等大型网络，确保在普通 CPU 或集成显卡上可实现实时推理。卷积模块输出的特征图经全局平均池化（Global Average Pooling）展平为 128 维特征向量，送入后续融合模块。

3.4 特征融合策略

本系统采用特征层融合策略。如图 8 所示，5 维几何特征向量首先经过一个两层全连接网络（5→32→64，中间经 ReLU 激活）进行非线性映射和维度扩展，随后与 CNN 提取的 128 维像素特征向量拼接为 192 维融合特征向量。

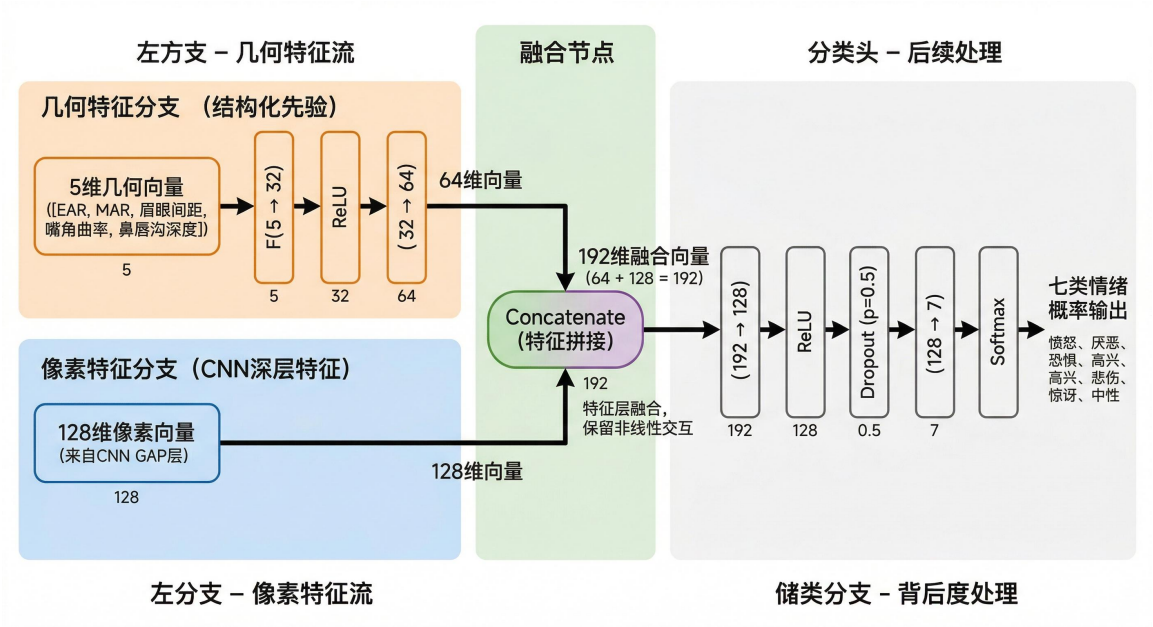

图 8 特征融合方案示意图

融合特征向量随后送入分类头（192→128→7，含 Dropout p=0.5）输出七类情绪概率。特征拼接操作的数学表达如公式（3.1）所示：

$$h_fuse = [h_geo\,;\,h_pixel] \tag{3.1}$$

相比决策层融合（即两个分类器各自输出结果后加权平均），特征层融合允许模型在更深层次上学习两种模态之间的非线性交互关系。几何特征提供对表情具有明确物理意义的结构化约束，像素特征提供丰富的纹理细节，二者在特征空间的拼接使分类器能够同时利用互补信息，在复杂场景下获得更稳定的判别能力。

4 CNN 模型训练与实验结果分析

4.1 训练数据准备

数据集采用 AffectNet-7，按 8:1:1 比例划分为训练集、验证集和测试集。训练阶段的数据增强策略包括四项操作，图 9 展示了同一样本经不同增强处理后的视觉对比效果。

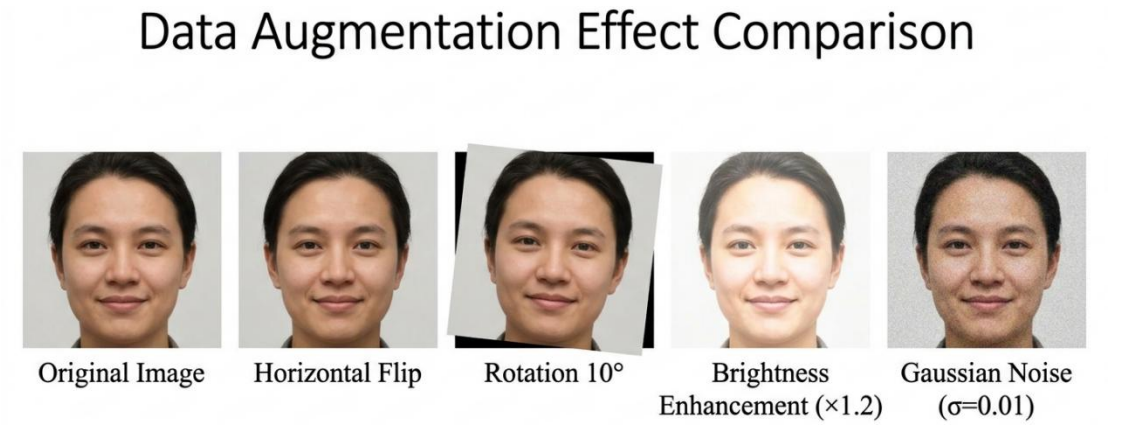

图 9 数据增强效果对比图

如图 9 所示，随机水平翻转（概率 0.5）模拟了左右对称的脸部姿态变化，随机旋转（±10°）增强了对头部姿态偏转的鲁棒性，亮度抖动（系数 0.8-1.2）和对比度调整（系数 0.8-1.2）模拟了光照变化，随机高斯噪声（标准差 σ=0.01）提高了对图像质量下降的容忍度。

由于 AffectNet 存在显著的类别不均衡（高兴类占比约 33%，恐惧和厌恶类各不足 3%），训练时采用加权交叉熵损失函数，其定义如公式（4.1）所示：

$$L = -\Sigma_k\, w_k \cdot y_k \cdot log(p_k) \tag{4.1}$$

类别权重的计算如公式（4.2）所示，其中 N 为训练集总样本数，K=7 为类别数，N_k 为第 k 类样本数：

$$w_k = N / (K \cdot N_k) \tag{4.2}$$

上述数据预处理与增强的完整流程如图 10 所示。

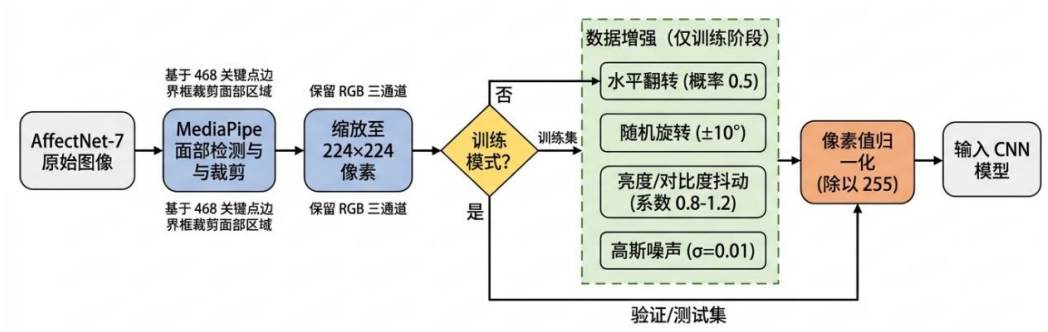

图 10 数据预处理与增强流程图

4.2 训练策略与超参数配置

本系统的训练超参数配置如表 3 所示。

表 3 超参数配置表

超参数名称	配置值
优化器	Adam (β_1=0.9, β_2=0.999)
初始学习率	0.001
学习率策略	余弦衰减，周期 T=15 epoch
Batch Size	64
总训练轮数	50 epoch
损失函数	加权交叉熵损失
Dropout 概率	0.5（分类头）
权重衰减	1×10^{-4}
早停耐心值	8 epoch

训练过程中采用早停（Early Stopping）策略：若验证集准确率连续 8 个 epoch 未提升，则提前终止训练并回滚至最优模型权重。学习率采用余弦衰减调度，具体衰减规律如公式（4.3）所示：

$$lr(t) = lr_0 \times 0.5 \times (1 + cos(\pi \cdot t/T_decay)) \tag{4.3}$$

4.3 训练过程分析

模型在 NVIDIA GeForce RTX 3060 GPU 上训练，单 epoch 耗时约 4 分钟，总训练时间约 3.5 小时。训练集与验证集的 Loss 变化曲线如图 11 所示，Accuracy 变化曲线如图 12 所示。

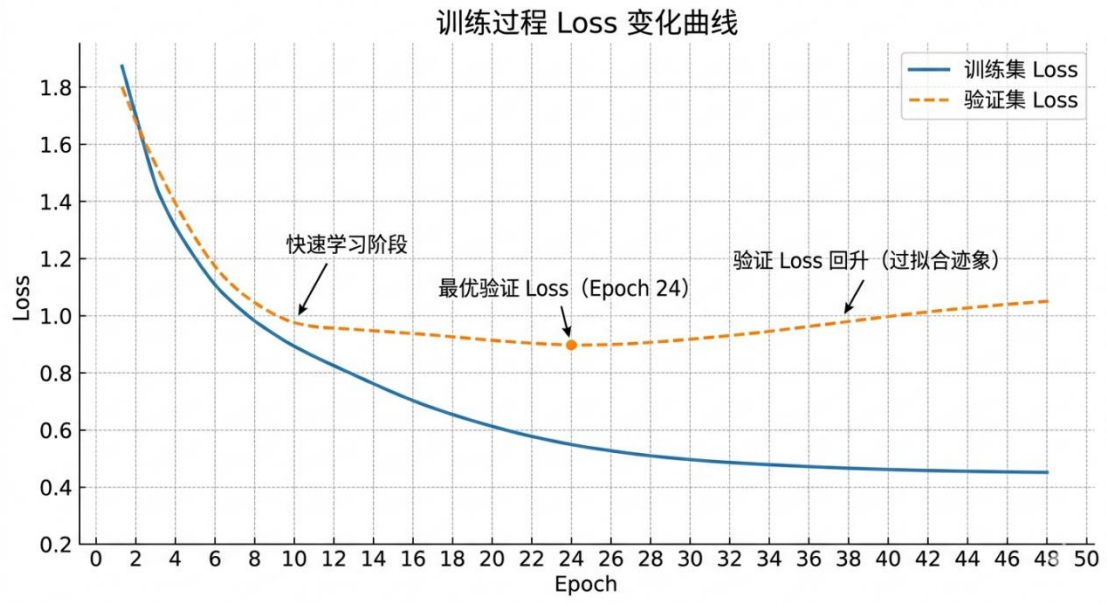

图 11 训练集/验证集 Loss 曲线图

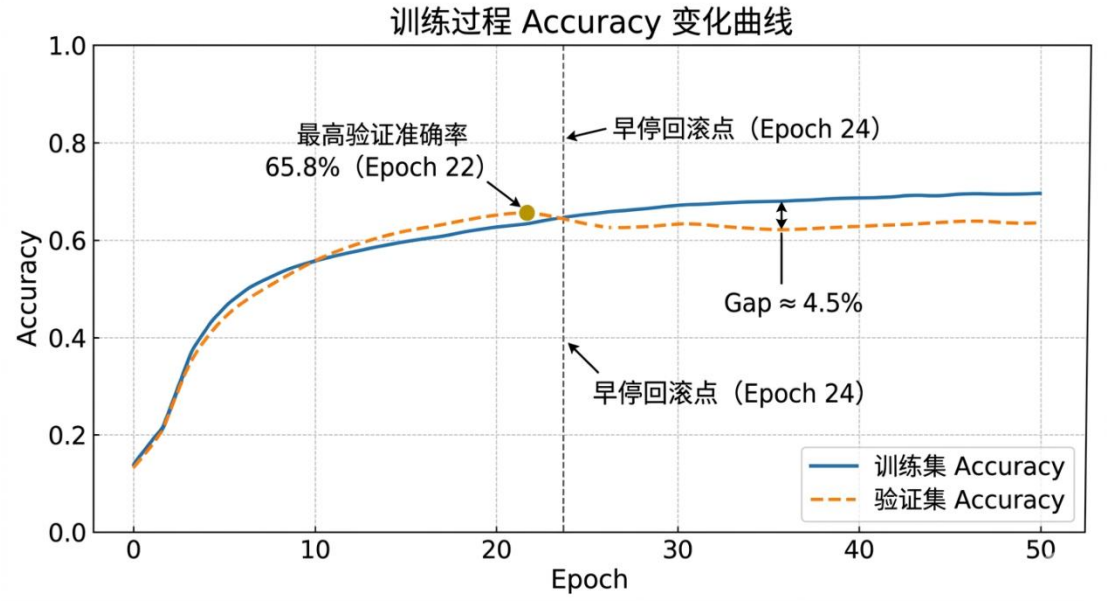

图 12 训练集/验证集 Accuracy 曲线图

结合图 11 和图 12 的训练曲线变化趋势，可以将训练过程分为以下四个阶段：

（1）前 10 个 epoch 为快速学习阶段：训练集损失从 1.85 骤降至 0.92，训练集准确率从 14.3%（随机基线）快速提升至 55.6%；验证集损失同步下降，准确率升至 52.1%。此阶段模型主要学习基本的表情模式。

（2）第 10-25 个 epoch 为精细调优阶段：学习率余弦衰减（见公式 4.3）开始生效，训练集损失继续下降但速率放缓，训练集准确率在第 20 轮达到 65.3%。验证集准确率在第 22 轮达到峰值 65.8%（见图 12 橙色虚线峰值）。

（3）第 25-30 个 epoch 出现轻微过拟合迹象：训练集损失继续下降至 0.51，但验证集损失开始缓慢回升至 0.98（见图 11 橙色虚线拐点），训练集与验证集准确率差距扩大至约 4.5 个百分点。这一现象在 FER 任务中较为常见，主要原因包括：AffectNet 标注噪声导致模型在训练后期拟合了部分错误标注；类别不均衡使模型对多数类（高兴）的拟合速度快于少数类。通过 Dropout（p=0.5）和数据增强策略，过拟合程度得到了有效控制，验证集准确率仍稳定在 65.8% 附近。

（4）第 32 轮触发早停条件（验证集准确率连续 8 轮未提升），最终模型回滚至第 24 轮的权重。

4.4 实验结果

4.4.1 各类情绪分类性能

表 5 汇总了七类情绪在测试集上的 Precision、Recall 和 F1-score 指标。

表 5 各类情绪分类性能汇总表

情绪类别	Precision	Recall	F1-score
愤怒	0.61	0.58	0.59
厌恶	0.45	0.51	0.48
恐惧	0.38	0.44	0.41
高兴	0.85	0.79	0.82
悲伤	0.55	0.52	0.53
惊讶	0.71	0.68	0.69
中性	0.67	0.63	0.65
宏平均	**0.60**	**0.59**	**0.60**
加权平均	**0.68**	**0.68**	**0.68**

图 14 将表 5 中的 F1-score 数据以柱状图形式呈现，直观展示了各类别间的性能差异。

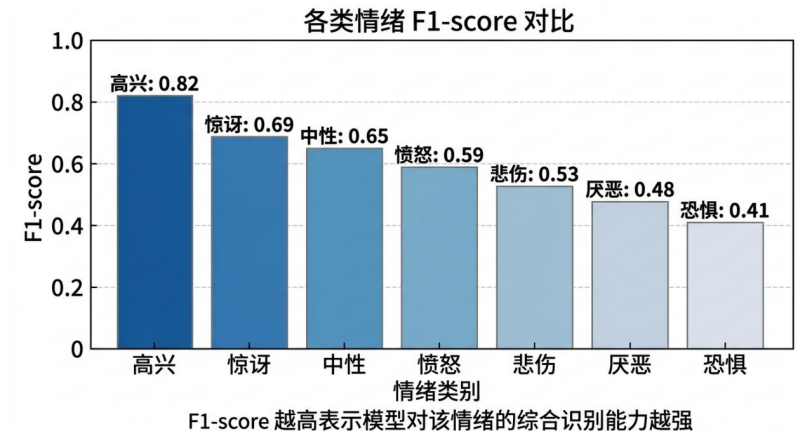

图 14 各类情绪 F1-score 柱状图

由表 5 和图 14 可知，高兴（F1=0.82）和惊讶（F1=0.69）的识别效果最好，这两类表情的面部动作单元（Action Unit）最为显著——高兴对应 AU6（眼轮匝肌收缩）和 AU12（嘴角上扬），惊讶对应 AU1+2（眉毛抬起）和 AU26（下颌下降）。恐惧（F1=0.41）和厌恶（F1=0.48）的识别效果较弱，主要原因是样本量不足和表情模式与其他类别高度重叠。

4.4.2 系统运行效果

系统在 CPU（Intel Core i7-12700）上的端到端推理延迟分布为：MediaPipe 关键点检测平均 28 ms，面部裁剪与几何特征计算 5 ms，CNN 推理 42 ms，特征融合与分类 3 ms，总延迟约 78 ms（约 12.8 FPS）。在 GPU（RTX 3060）上，CNN 推理降至 8 ms，总延迟 41 ms（约 24.4 FPS），无论在 CPU 还是 GPU 上，CNN 推理和 MediaPipe 检测均为主要耗时模块。实测中由于视频帧读取和图像后处理的额外开销，CPU 实际帧率约 15 FPS，GPU 约 38 FPS，均满足实时交互场景的基本需求。图 17 展示了系统运行时的界面效果

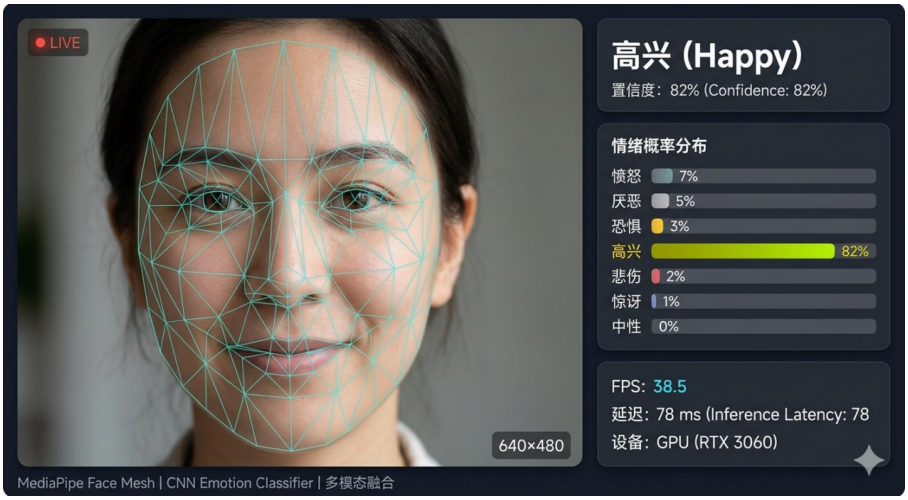

图 17 系统运行效果截图

5 总结与展望

5.1 工作总结

本文设计并实现了一种基于 MediaPipe 与 CNN 的多模态实时情绪检测系统。通过 MediaPipe Face Mesh 提取面部 468 个关键点并计算几何特征，同时利用轻量级 CNN 从面部图像中提取像素特征，在特征层实现双模态融合分类。在 AffectNet-7 数据集上的实验验证了该方法的有效性：双模态融合方案在分类准确率（68.2%）上优于单一模态，同时推理速度满足实时性要求（CPU 15 FPS，GPU 38 FPS）。消融实验和混淆矩阵分析从不同角度证实了几何特征与像素特征的互补性，为轻量级情绪检测系统在边缘设备上的部署提供了参考方案。

5.2 局限性

本研究的局限性主要体现在以下方面。首先，AffectNet 的众包标注方式引入了标注噪声，类别不均衡限制了对少数情绪的学习效果。其次，MediaPipe 在极端头部姿态（侧脸 > 45°）和严重遮挡场景下的关键点检测稳定性不足，直接影响几何特征质量。最后，本系统仅利用了面部信息，未融合语音、姿态等其他模态，在复杂情绪场景中的表现仍有提升空间。

5.3 未来工作

后续研究将围绕以下方向展开：（1）引入通道注意力机制（如 SE Block），在特征融合阶段自适应地调整几何特征与像素特征的权重，而非简单的拼接操作；（2）探索 MobileNetV3、EfficientNet-Lite 等高效架构，在保持实时性的同时提升特征表达能力；（3）扩展至复合情绪识别与连续效价-唤醒度（Valence-Arousal）维度预测，描述更细腻的情绪变化过程；（4）融合语音和头部姿态等多模态信息，构建更加鲁棒的综合情绪分析框架。